

Сотникова Ж.О.,

Московский государственный университет технологий и управления имени К. Г. Разумовского (Первый казачий университет), Москва, Россия

Научный руководитель: **Никаноров М.С.,**

Московский государственный университет технологий и управления имени К. Г. Разумовского (Первый казачий университет), Москва, Россия

Классификация листьев томата на основе алгоритмов машинного обучения

В данной статье представлена информация о алгоритмах компьютерного зрения, которое используется в сельском хозяйстве для обработки и интерпретации визуальной информации. Технология позволяет машинам распознавать закономерности, формы и цвета, уникальные для каждого типа сельскохозяйственной культуры. Целью данной работы является сравнительный анализ эффективности различных алгоритмов машинного обучения для решения задачи бинарной классификации изображений листьев томата. Результатом должен стать выбор оптимальной модели для разработки программного обеспечения, специализирующегося на распознавании фитофтороза у томатов.

Ключевые слова: машинное обучение, XGBoost, случайный лес, свёрточные нейронные сети, классификация изображений.

Sotnikova Z.O.,

Moscow State University of Technology and Management named after K. G. Razumovsky (First Cossack University), Moscow, Russia

Scientific Director: **Nikanorov M.S.**

Moscow State University of Technology and Management named after K. G. Razumovsky (First Cossack University), Moscow, Russia

Tomato Leaf Classification Using Machine Learning Algorithms

This article presents information about computer vision algorithms used in agriculture for processing and interpreting visual information. This technology allows machines to recognize patterns, shapes, and colors specific to different agricultural crop types. The objective of this study is to conduct a comparative analysis of the effectiveness of various machine learning algorithms for binary classification of tomato leaf images. The expected outcome is the selection of an optimal model for developing software dedicated to the recognition of late blight in tomatoes.

Keywords: Machine learning, XGBoost, random forest, convolutional neural networks, image classification.

Рецензия

Представленная работа посвящена актуальной проблеме применения технологий машинного обучения для диагностики фитофтороза томатов — заболевания, способного нанести значительный ущерб сельскохозяйственному производству. Автор проводит комплексный сравнительный анализ эффективности четырёх различных алгоритмов машинного обучения, что позволяет выявить оптимальные решения для практического применения в агропромышленном комплексе. Особую ценность исследованию придаёт детальный подход к оценке каждого алгоритма, включая подробное описание параметров обучения, архитектуры моделей и метрик качества. Работа отличается высоким уровнем технической проработки материала, подкреплённого обширными экспериментальными данными и наглядными таблицами результатов. Автор убедительно демонстрирует превосходство ансамблевых методов, особенно XGBoost, который показал наилучшее сочетание точности (99,62%), скорости обучения (0,40 мин) и полноты обнаружения заболевания. При этом проведённый анализ позволяет

обоснованно рекомендовать Random Forest для сценариев, где критически важно исключить пропуск заболевания. К достоинствам работы можно отнести чёткую постановку задачи, структурированность изложения и практическую значимость полученных результатов. Исследование вносит существенный вклад в развитие методов автоматизированной диагностики заболеваний растений и может служить основой для создания эффективных систем мониторинга фитофтороза. Единственным замечанием является относительно краткое описание процесса предобработки данных, хотя этот этап играет важную роль в качестве конечного результата. Тем не менее, представленная работа является глубоким и всесторонним исследованием, заслуживающим внимания специалистов в области машинного обучения и агропромышленного комплекса.

Красовская Л. В., доцент, к.т.н.

Федеральное государственное бюджетное образовательное учреждение высшего образования «Российский государственный аграрный университет — МСХА имени К. А. Тимирязева», г. Москва, Россия

Krasovskaya L.V.

Federal State Budgetary Educational Institution of Higher Education “Russian State Agrarian University — Moscow Timiryazev Agricultural Academy”, Moscow, Russia

Введение

Искусственный интеллект применяется в агропромышленном комплексе для автоматизации анализа данных, моделирования, принятия решений и управления оборудованием. ИИ используется не точечно, а по всей производственной цепочке, закрывает задачи, где человеку сложно обрабатывать большие объёмы информации [15]. В АПК востребованы такие технологии, как машинное и глубокое обучение, нейронные сети, компьютерное зрение, системы поддержки принятия решений и обработка больших данных. Достижения в сфере компьютерного зрения и машинного обучения, особенно в области глубокого обучения и ансамблевых алгоритмов, открывают новые возможности для решения задач связанных с проблемами в агропромышленном комплексе. Одной из такой проблем является заболевание фитофтороз. На начальной стадии болезнь легко перепутать с проявлениями дефицита освещения, тепла или микроэлементов. Когда фитофтороз переходит в активную стадию развития, остановить его сложно. Проще не допустить развитие болезни, чем ее лечить. Нужны постоянные профилактические обработки и комплексная работа [1].

Традиционные методы диагностики, основанные на визуальном осмотре полей, являются субъективными, трудоемкими и не всегда своевременными. Лабораторные методы такие как ПЦР-диагностика и иммуноферментный анализ обладают высокой точностью, но требуют дорогостоящего оборудования [14], реактивов и времени, что неприемлемо для оперативного принятия решений в полевых условиях. В этой связи особую актуальность приобретает разработка автоматизированных систем диагностики,

которые могли бы быть интегрированы в качестве прикладного решения для агропромышленного комплекса.

Компьютерное зрение используется в сельском хозяйстве для обработки и интерпретации визуальной информации. Технология позволяет машинам распознавать закономерности, формы и цвета, уникальные для каждого типа сельскохозяйственной культуры [16]. Применение этих методов к анализу листьев на примере томата для выявления экземпляров, которые поражены фитофторозом, способствует созданию высокоточных, доступных и оперативных средств диагностики фитосанитарного состояния растений.

Алгоритмы машинного обучения для задачи классификации

Для решения задачи бинарной классификации изображений листьев томата были отобраны четыре алгоритма машинного обучения, представляющие различные подходы: от классических методов до глубоких нейросетей. В качестве базового уровня выбран метод опорных векторов (SVM) в комбинации с дескрипторами HOG, что позволяет оценить эффективность автоматического выделения признаков. Для анализа ансамблевых методов были привлечены такие алгоритмы как случайный лес (Random Forest) и градиентный бустинг (XGBoost), которые демонстрируют высокую эффективность при работе с табличными признаками (цветовые гистограммы, текстуры) и низкие вычислительные затраты. Для сравнения с современными подходами в области компьютерного зрения была разработана свёрточная нейронная сеть (CNN), способная автоматически извлекать иерархические признаки из изображений. Такая комбинация алгоритмов позволяет не только сравнить их по точности и полноте, но и оценить применимость в условиях агропромышленных комплексов, где критически важны скорость обучения и интерпретируемость результатов.

SVM (Support Vector Machine) — алгоритм машинного обучения, который находит границу между классами объектов [8]. Основная идея метода: перевод исходных векторов в пространство более высокой размерности и поиск разделяющей гиперплоскости с максимальным зазором в этом пространстве. Если линейную плоскость провести невозможно, алгоритм предварительно трансформирует данные так, чтобы их можно было разделить с помощью гиперплоскости [9]. HOG (Histogram of Oriented Gradients) — алгоритм, который основан на подсчёте количества направлений градиента в локальных областях изображения.

Случайный лес (Random Forest) представляет собой ансамблевый метод, основанный на построении множества деревьев решений и усреднении их результатов [11].

XGBoost (eXtreme Gradient Boosting) — это реализация градиентного бустинга, последовательно обучающая деревья решений с исправлением ошибок предыдущих [12].

Сверточные нейронные сети (CNN, Convolutional Neural Networks) — класс алгоритмов глубокого обучения, специально разработанных для обработки данных с пространственной структурой, таких как изображения. Основаны на математической операции свёртки, которая позволяет выделять локальные признаки в данных [13].

Таблица 1. Характеристика алгоритмов машинного обучения

Метод	Тип метода	Принцип работы	Основное применение	Преимущества
SVM + HOG	Классический ML	Извлечение признаков HOG + линейное разделение гиперплоскостью	Базовый уровень сравнения	Интерпретируемость, низкие требования к данным
Random Forest	Ансамбль деревьев	Усреднение результатов множества деревьев, построенных на разных выборках	Скрининг с требованием 100% обнаружения	Высокая скорость, устойчивость к переобучению
XGBoost	Градиентный бустинг	Последовательное обучение деревьев с исправлением ошибок предыдущих	Оптимальный баланс точности и скорости для мобильных приложений	Высокая точность, интерпретируемость, компактность
CNN	Глубокое обучение	Автоматическое иерархическое извлечение признаков через свёрточные слои	Задачи, требующие максимальной точности без ложных тревог	Высокая точность положительных предсказаний, требует больших вычислительных ресурсов

В процессе первичной обработки изображений применялись следующие методы:

1. Изменение размера (Resizing) – процесс преобразования изображений в машинном обучении, который позволяет унифицировать входные данные для моделей, требующих определённого размера (224×224 пикселя) [4].

2. Нормализация – процедура предобработки входной информации (обучающих, тестовых и валидационных выборок, а также реальных данных), при которой значения признаков во входном векторе приводятся к диапазону [0,1] [5].

3. Разделение выборки – это процесс разбиения исходного набора данных на обучающую выборку (70%), тестовую (15%) и валидационную выборку (15%) [6].

4. Аугментация данных – техника искусственного расширения обучающего набора данных путём создания модифицированных версий имеющихся примеров (Таблица 2) для повышения обобщающей способности моделей и предотвращения переобучения [7].

Таблица 2. Параметры аугментации данных

Тип аугментации	Параметры
Вращение (rotation_range)	20°
Сдвиг по горизонтали (width_shift_range)	0.2
Сдвиг по вертикали (height_shift_range)	0.2
Сдвиг (shear_range)	0.2
Масштабирование (zoom_range)	0.2
Отражение по горизонтали (horizontal_flip)	True
Стратегия заполнения (fill_mode)	'nearest'
Нормализация (rescale)	1./255

Одним из способов проверки качества обученной модели является матрица ошибок. Матрица ошибок — таблица, используемая для визуализации и оценки эффективности модели классификации. Основное назначение матрицы — представить в наглядном виде, как часто модель правильно классифицирует объекты и какие именно ошибки она совершает.

	Actually Positive	Actually Negative
Predicted Positive	True Positives (TP)	False Positive (FP)
Predicted Negative	False Negatives (FN)	True Negatives (TN)

Рисунок 1 – Матрица ошибок

Для оценки эффективности моделей также использовалась стандартная метрика, вычисляемая на основе матрицы ошибок – точность (ассигасу) – доля правильных ответов модели от общего количества примеров. Так же существуют ещё метрики оценки качества модели [17], но приоритетной всё равно остаётся именно точность.

Для обучения и оценки моделей использовался датасет PlantVillage [18], содержащий размеченные изображения листьев сельскохозяйственных культур с различными заболеваниями. Из полного набора данных были отобраны две категории изображений томата: здоровые листья (Tomato_healthy) и листья, поражённые фитофторозом (Tomato_Late_blight). В итоговую выборку вошло 1591 изображение здоровых растений и 1909 изображений с признаками заболевания.



Рисунок 2 – Здоровые листья из датасета



Рисунок 3 – Листья, поражённые фитофторозом из датасета

На основе сформированного датасета было проведено обучение четырёх алгоритмов машинного обучения, различающихся по принципам работы, вычислительной сложности

и интерпретируемости результатов. Для каждого алгоритма подбирались оптимальные гиперпараметры (Таблицы 3, 4, 5, 6), обеспечивающие максимальную точность при сохранении устойчивости к переобучению.

Таблица 3. Параметры обучения модели SVM

Параметр	Значение	Обоснование
Тип ядра (kernel)	RBF (Radial Basis Function)	Обеспечивает нелинейное разделение классов
Параметр регуляризации (C)	10	Контролирует компромисс между максимизацией зазора и минимизацией ошибок
Коэффициент ядра (gamma)	'Scale'	Автоматический расчёт как $1/(n_features * X.var())$
Извлечение признаков	HOG (Histogram of Oriented Gradients)	Описывает распределение градиентов яркости
Параметры HOG	Orientations=9, pixels_per_cell=(8,8), cells_per_block=(2,2)	Стандартные параметры для задач классификации изображений
Случайное состояние (random_state)	42	Обеспечивает воспроизводимость результатов

Таблица 4. Параметры обучения модели Random Forest

Параметр	Значение	Обоснование
Количество деревьев (n_estimators)	100	Достаточно для стабилизации предсказаний
Максимальная глубина дерева (max_depth)	20	Ограничивает переобучение
Минимальное количество образцов для разделения узла (min_samples_split)	5	Предотвращает создание слишком глубоких деревьев
Минимальное количество образцов в листе (min_samples_leaf)	2	Сглаживает предсказания на малых подвыборках
Количество ядер для	-1	Использует все доступные

параллелизации (n_jobs)		процессорные ядра
Случайное состояние (random_state)	42	Обеспечивает воспроизводимость
Режим вывода (verbose)	1	Отображение прогресса обучения

Таблица 5. Параметры обучения модели XGBoost

Параметр	Значение	Обоснование
Количество деревьев (n_estimators)	100	Обеспечивает достаточную сложность модели
Максимальная глубина дерева (max_depth)	6	Контролирует переобучение
Скорость обучения (learning_rate)	0.1	Компромисс между скоростью и качеством обучения
Доля выборки для построения дерева (subsample)	0.8	Снижает переобучение
Доля признаков для каждого дерева (colsample_bytree)	0.8	Увеличивает разнообразие деревьев
Функция потерь (eval_metric)	'logloss'	Бинарная кросс-энтропия для классификации
Использование кодировщика меток (use_label_encoder)	False	Отключает устаревший кодировщик
Случайное состояние (random_state)	42	Обеспечивает воспроизводимость
Режим вывода (verbosity)	1	Отображение прогресса обучения

Разработанная сверточная нейронная сеть (CNN) состоит из трёх сверточных блоков, каждый из которых включает два сверточных слоя с последующей пакетной нормализацией (BatchNormalization), слоем субдискретизации (MaxPooling) и dropout для регуляризации. Завершает сеть полносвязный классификатор с двумя скрытыми слоями и сигмоидальным выходным нейроном для бинарной классификации. Архитектура сети представлена в таблице 7.

Таблица 6. Параметры обучения модели CNN

Параметр	Значение	Обоснование
----------	----------	-------------

Оптимизатор	Adam	Адаптивный метод, хорошо зарекомендовавший себя для задач компьютерного зрения
Скорость обучения (learning_rate)	0.001	Стандартное значение для Adam
Функция потерь (loss)	binary_crossentropy	Бинарная кросс-энтропия для двух классов
Метрики оценки	accuracy, precision, recall	Отслеживание качества в процессе обучения
Размер батча (batch_size)	32	Компромисс между скоростью и стабильностью градиента
Ранняя остановка (EarlyStopping)	patience=10	Прекращение обучения при отсутствии улучшений на валидации
Сохранение лучшей модели (ModelCheckpoint)	save_best_only=True	Сохраняет веса с наименьшей ошибкой на валидации
Случайное состояние (random_state)	42	Обеспечивает воспроизводимость разделения данных

Таблица 7. Архитектура свёрточной нейронной сети

№	Слой	Параметры	Размер выхода	Число параметров
1	Conv2D	32 фильтра, 3×3, ReLU, padding='same'	224×224×32	896
2	BatchNormalization	-	224×224×32	128
3	Conv2D	32 фильтра, 3×3, ReLU, padding='same'	224×224×32	9,248
4	BatchNormalization	-	224×224×32	128
5	MaxPooling2D	2×2	112×112×32	0
6	Dropout	0.25	112×112×32	0
7	Conv2D	64 фильтра, 3×3, ReLU, padding='same'	112×112×64	18,496
8	BatchNormalization	-	112×112×64	256

9	Conv2D	64 фильтра, 3×3, ReLU, padding='same'	112×112×64	36,928
10	BatchNormalization	-	112×112×64	256
11	MaxPooling2D	2×2	56×56×64	0
12	Dropout	0.25	56×56×64	0
13	Conv2D	128 фильтров, 3×3, ReLU, padding='same'	56×56×128	73,856
14	BatchNormalization	-	56×56×128	512
15	Conv2D	128 фильтров, 3×3, ReLU, padding='same'	56×56×128	147,584
16	BatchNormalization	-	56×56×128	512
17	MaxPooling2D	2×2	28×28×128	0
18	Dropout	0.25	28×28×128	0
19	Flatten	-	100,352	0
20	Dense	512 нейронов, ReLU	512	51,380,736
21	BatchNormalization	-	512	2,048
22	Dropout	0.5	512	0
23	Dense (выходной)	1 нейрон, sigmoid	1	513
	Итого			≈ 81,937

Результаты обучения моделей

С использованием описанных выше гиперпараметров было проведено обучение всех четырёх алгоритмов машинного обучения. Для каждой модели фиксировались метрики качества на валидационной выборке, а итоговая оценка производилась на тестовой выборке, не участвовавшей в процессе обучения. В таблице 8 представлены основные результаты обучения моделей.

Таблица 8. Сравнительные результаты алгоритмов машинного обучения

Модель	Accuracy (%)	Precision (%)	Recall (%)	F1-score	Время (мин)	FN	FP
SVM + HOG	87.2	86.1	84.5	0.85	0.5	31	45

Random Forest	96.95	94.7	100.0	0.9728	0.04	0	16
CNN	98.43	100.0	97.13	0.9854	125.15	11	0
XGBoost	99.62	99.65	99.65	0.9965	0.4	1	1

Модель, обученная алгоритмом опорных векторов, правильно классифицировала 207 здоровых и 208 больных растений. При этом было зафиксировано, что 45 здоровых растений были ошибочно приняты за больные и 31 больное растение было пропущено. Общая точность составила 87,20%. Высокое число пропущенных заболеваний является критическим недостатком, ограничивающим практическую применимость SVM в задачах скрининга фитофтороза.




Рисунок 4 – Матрица ошибок SVM

Разработанная сверточная нейронная сеть правильно классифицировала 690 из 701 изображения. Из 318 здоровых растений ни одно не было ошибочно принято за больное (Precision = 100%), однако 11 больных растений из 383 остались необнаруженными (Recall = 97,13%). Общая точность модели составила 98,43%. Время обучения сети составило 125,15 минут. Модель содержит 81 937 обучаемых параметров.




Рисунок 5 – Матрица ошибок CNN

Модель Random Forest правильно классифицировала 509 из 525 изображений. Из 239 здоровых растений 16 были ошибочно отнесены к классу «болен», однако ни одно больное растение не было пропущено – все 286 поражённых экземпляров выявлены корректно. Точность модели составила 96,95%. Время обучения модели – 0,04 минуты (2,4 секунды), что в сравнении со свёрточной нейронной сетью более чем в 3000 раз быстрее.




Рисунок 6 – Матрица ошибок Random Forest

Модель XGBoost правильно классифицирует 523 из 525 изображений. Только 1 здоровое растение принято за больное, а также только 1 больное растение было пропущено. Точность модели составила 99,62%. Время обучения – 0.40 мин (24 сек), что в 300 раз быстрее CNN.




Рисунок 7 – Матрица ошибок XGBoost

Проведенное исследование позволяет сформулировать следующие выводы:

1. Ансамблевые методы (Random Forest и XGBoost) демонстрируют значительное превосходство над классическим алгоритмом SVM, достигая результатов, сопоставимых с глубокими нейросетями, при существенно меньших вычислительных затратах.
2. Наилучшее соотношение между точностью, полнотой и временем обучения достигнуто для XGBoost (Accuracy — 99,62%, Recall — 99,65%, время обучения — 0,40 мин) (Рис. 8, Рис. 9). Единственная ошибка каждого типа позволяет рассматривать данную модель как практически оптимальную для диагностических задач.
3. Random Forest характеризуется полным обнаружением пораженных растений (Recall = 100%) при минимальном времени обучения (2,4 с) (Рис. 8, Рис. 9). Данная особенность делает его предпочтительным в сценариях, где критически важно исключить пропуск заболевания.
4. Сверточная нейронная сеть (CNN) обеспечивает максимальную точность положительных предсказаний (Precision = 100%) (Рис. 8), что исключает необоснованные

обработки здоровых растений. Однако значительная продолжительность обучения и наличие 11 пропущенных случаев заболевания снижают ее применимость в условиях агропромышленных комплексов.




Рисунок 8 – Диаграмма метрик качества




Рисунок 9 – Диаграмма времени обучения

Заключение

В ходе выполнения работы был проведен сравнительный анализ четырех алгоритмов машинного обучения для бинарной классификации изображений листьев томата с целью

выявления фитофтороза. На основе полученных экспериментальных данных сформулированы следующие итоги:

1. Ансамблевые методы (Random Forest и XGBoost) являются наиболее эффективными для решения поставленной задачи. Они сочетают высокое качество классификации (Ассурасу > 96%) с низкими вычислительными затратами, что делает их предпочтительными для практического применения по сравнению как с классическими методами (SVM), так и с глубокими нейросетями.

2. XGBoost признан оптимальным алгоритмом для реализации в агропромышленных комплексах. Модель демонстрирует наилучший баланс между полнотой обнаружения заболевания (99,65%), минимизацией ложных тревог (99,65%) и скоростью обучения (0,40 мин). Такое сочетание характеристик позволяет интегрировать алгоритм в приложения, работающие в полевых условиях без существенных требований к вычислительным ресурсам.

3. Выбор между XGBoost и Random Forest определяется приоритетом целевой метрики. Если критически важным является абсолютное исключение пропуска заболевания (Recall = 100%), предпочтение следует отдать Random Forest, который при этом демонстрирует рекордную скорость обучения. Если же требуется минимизация как ложноотрицательных, так и ложноположительных ошибок одновременно, оптимальным является XGBoost.

4. Сверточные нейронные сети, несмотря на высокую точность (98,43%) и отсутствие ложных тревог, имеют ограниченную применимость в контексте мобильных АПК. Длительное время обучения (125 мин) делают их менее гибкими для оперативного развертывания и адаптации.

5. Классический подход на основе SVM с извлечением признаков HOG не обеспечивает требуемого качества диагностики. Полученные результаты (Ассурасу 87,20%) подтверждают ограниченность методов, основанных на ручном выделении признаков, при решении задач распознавания болезней растений по визуальным изображениям.

Таким образом, в результате проведенного исследования обоснован выбор XGBoost в качестве наиболее сбалансированного алгоритма для создания системы диагностики фитофтороза томата, сочетающего высокую точность, надежность обнаружения заболевания и вычислительную эффективность.

Литература

1. Разработка наукоемкой технологии мониторинга на основе компьютерного зрения: оценка влияния репрезентативности данных на точность прогнозных моделей / М. Ю.

Карелина, А. А. Акулов, В. Д. Кутков, Д. С. Талдыкин // Научные технологии в космических исследованиях Земли. – 2025. – Т. 17, № 5. – С. 48-58. – DOI 10.36724/2409-5419-2025-17-5-48-58. – EDN ZAVFSC.

2. Помогаев, П. П. Исследование массивов данных о заболеваниях растений методами машинного обучения для их определения и классификации / П. П. Помогаев, К. И. Будников // Математическое и компьютерное моделирование : сборник материалов XI Международной научной конференции, посвященной памяти В.А. Романькова, Омск, 15 марта 2024 года. – Омск: Омский государственный университет им. Ф.М. Достоевского, 2024. – С. 212-214. – EDN YGIVFH.

3. Тананыкина, Л. В. Метод предобработки изображений в системах компьютерного зрения / Л. В. Тананыкина // Информационные технологии и нанотехнологии : Материалы Международной конференции и молодежной школы, Самара, 29 июня – 01 июля 2015 года / Федеральное государственное автономное образовательное учреждение высшего образования «Самарский государственный аэрокосмический университет имени академика С.П. Королева (Национальный исследовательский университет)». – Самара: Самарский научный центр РАН, 2015. – С. 70-74. – EDN UBSRBH.

4. Старовойтов, В. В. Нормализация данных в машинном обучении / В. В. Старовойтов, Ю. И. Голуб // Информатика. – 2021. – Т. 18, № 3. – С. 83-96. – DOI 10.37661/1816-0301-2021-18-3-83-96. – EDN JKANKM

5. Беженцев, А. А. О применении информационной системы "Автоматизация деятельности комиссий по делам несовершеннолетних и защите их прав" / А. А. Беженцев // Региональная информатика "РИ-2014" : материалы XIV Санкт-Петербургской международной конференции, Санкт-Петербург, 29–31 октября 2014 года. – Санкт-Петербург: Санкт-петербургское общество информатики, связи и управления, 2014. – С. 173. – EDN TIUAPR.

6. Алимагадов, К. А. Аугментация данных на основе вейвлет-фильтрации при обучении нейронных сетей / К. А. Алимагадов, С. В. Умняшкин // Труды Международной конференции по компьютерной графике и зрению "Графикон". – 2023. – № 33. – С. 437-442. – DOI 10.20948/graphicon-2023-437-442. – EDN MAOBLK.

7. Кривалова, С. В. Об одном из способов детекции дефектов автоматического посева хвойных деревьев с помощью компьютерного зрения / С. В. Кривалова, А. А. Куприянова, А. В. Вылегжанина // Фундаментальные и прикладные исследования в информатике и цифровизации : Материалы симпозиума XX (LII) Международной научной конференции студентов, аспирантов и молодых ученых, посвященной 80-й годовщине Победы в Великой Отечественной войне, Кемерово, 24 апреля 2025 года. – Кемерово: Кемеровский государственный университет, 2025. – С. 81-84. – EDN MZIYLK.

8. Масич, И. С. Распознавание видов растений по изображениям листьев с помощью методов машинного обучения / И. С. Масич // Наука и образование: опыт, проблемы, перспективы развития : материалы XIV международной научно-практической конференции, Красноярск, 22–23 апреля 2015 года / Ответственные за выпуск: А.А. Кондрашев, Е.И. Сорокатая. Том Часть II. – Красноярск: Красноярский государственный аграрный университет, 2015. – С. 294-296. – EDN VOUIYP.

9. Клюев, В. В. Обнаружение объектов на изображениях с помощью гистограммы направленных градиентов / В. В. Клюев // Аллея науки. – 2019. – Т. 2, № 2(29). – С. 913-917. – EDN MSPEEV.

10. Арм, А. А. С. Новая гибридная модель обнаружения аномалий с использованием ансамблевого машинного обучения и федеративных графовых нейронных сетей для обеспечения сетевой безопасности / А. А. С. Арм, Е. В. Ляпунцова // Моделирование, оптимизация и информационные технологии. – 2025. – Т. 13, № 2(49). – DOI 10.26102/2310-6018/2025.49.2.044. – EDN RWFREG.

11. Чорный, Д. А. Сравнительный анализ алгоритмов градиентного бустинга для задач классификации / Д. А. Чорный // Обработка информации и математическое моделирование:

Материалы Российской научно-технической конференции, Новосибирск, 26–27 апреля 2017 года. – Новосибирск: Сибирский государственный университет телекоммуникаций и информатики, 2017. – С. 208-215. – EDN ZCBCIB.

12. Васкан, В. Д. Обзор архитектур сверточных нейронных сетей для задачи классификации изображений / В. Д. Васкан // ИТ-Стандарт. – 2021. – № 3(28). – С. 34-39. – EDN WQQUFN.

13. Сурина, Т. А. Фитофторозные корневые гнили древесных и кустарниковых растений и их диагностика : специальность 03.02.12 "Микология" : автореферат диссертации на соискание ученой степени кандидата биологических наук / Сурина Татьяна Александровна. – Москва, 2015. – 22 с. – EDN ZPPMZH.

14. Редун, Р. И. Применение технологий искусственного интеллекта в агропромышленном комплексе / Р. И. Редун, Е. Э. Удовик // Инновационная экономика: перспективы развития и совершенствования. – 2025. – № 8(90). – С. 69-76. – EDN WLUYSB.

15. Попов, Н. Е. Применение технологий обучения с учителем и компьютерного зрения в сельском хозяйстве / Н. Е. Попов // Молодые исследователи агропромышленного и лесного комплексов – регионам, Вологда, 03 апреля 2025 года. – Вологда-Молочное: ФГБОУ ВО Вологодская ГМХА, 2025. – С. 163-167. – EDN EXCFEY.

16. Васильева, О. Г. Выбор метрики для оценки качества в моделях машинного обучения / О. Г. Васильева, О. Г. Афанасьева // Перспективные технологии и инновации в АПК в условиях цифровизации : Материалы IV Международной научно-практической конференции, Чебоксары, 07 февраля 2025 года. – Чебоксары: Чувашский государственный аграрный университет, 2025. – С. 235-237. – EDN BXTGJP